

Аналіз аудіофіч треків Spotify та прогноз популярності

Проект з дисципліни “Інтелектуальний аналіз даних”

Студент: Масич Нікіта

Група: АСД

Курс: 1 курс магістратури

Університет: Київський національний університет імені Тараса Шевченка

Факультет: Факультет комп’ютерних наук та кібернетики

Навчальний рік: 2026

Анотація

У цій роботі досліджено набір аудіофіч треків Spotify з метою аналізу взаємозв’язків між характеристиками композицій, жанровими групами та популярністю треків. Робота поєднує описовий аналіз даних, візуалізацію, кластеризацію та базове машинне навчання для побудови інтерпретованого та відтворюваного дослідження.

Ключові слова: інтелектуальний аналіз даних, Spotify, кластеризація, класифікація, аудіофічі, популярність треків.

1. Вступ і мотивація

Стрімінгові музичні платформи генерують значні обсяги даних про музичні композиції, поведінку користувачів та характеристики аудіоконтенту. Такі дані є цінним джерелом інформації для задач інтелектуального аналізу даних, оскільки дозволяють досліджувати закономірності популярності музики, взаємозв’язки між жанрами та аудіофічами, а також виконувати класифікацію й кластеризацію треків.

Платформа Spotify надає набір аудіофіч, які описують композиції з точки зору ритму, енергійності, танцювальності, акустичності, темпу та інших параметрів. Аналіз таких характеристик дозволяє досліджувати структуру музичних даних та визначати фактори, що найбільше впливають на популярність композицій.

Метою цієї роботи є проведення комплексного аналізу набору даних Spotify Tracks Dataset із використанням методів інтелектуального аналізу даних та машинного навчання. У межах дослідження виконано попередню обробку даних, описовий аналіз, кореляційний аналіз, кластеризацію треків та побудову моделей класифікації популярності композицій.

Основними завданнями роботи є:

1. Аналіз структури та характеристик набору даних.
2. Дослідження взаємозв’язків між аудіофічами.
3. Виявлення груп подібних треків за допомогою кластеризації.
4. Побудова моделей машинного навчання для про-

гнозування популярності треків.

5. Інтерпретація отриманих результатів.

Набір даних містить інформацію про понад 100 тисяч музичних композицій різних жанрів. Це забезпечує достатню репрезентативність вибірки для проведення аналізу та отримання практично значущих результатів.

2. Поточний стан досліджень

Задачі аналізу музичних даних активно досліджуються у сфері інтелектуального аналізу даних та машинного навчання. Одним із ключових напрямків є дослідження аудіофіч музичних композицій для побудови рекомендаційних систем, прогнозування популярності треків та автоматичної класифікації жанрів.

У сучасних музичних сервісах використовуються алгоритми машинного навчання для персоналізації рекомендацій та аналізу поведінки користувачів. Spotify застосовує аудіофічі, які формуються на основі цифрової обробки сигналів та статистичного аналізу музичних характеристик.

У багатьох дослідженнях використовуються методи кластеризації для групування композицій за схожими ознаками. Найбільш поширеним алгоритмом є KMeans, який дозволяє ефективно виявляти приховані структури у великих наборах даних.

Також активно застосовуються методи класифікації для прогнозування популярності треків. Для цього використовуються алгоритми Logistic Regression, Random Forest, Gradient Boosting та нейронні мережі. Практика показує, що ансамблеві методи часто демонструють кращі результати для музичних даних через нелінійні взаємозв’язки між ознаками.

У даній роботі використовується комбінація класичних методів аналізу даних та машинного навчання, що дозволяє побудувати інтерпретоване та відтворюване дослідження без використання складних глибоких нейронних мереж.

3. Методи та результати

Для проведення дослідження використовувався набір даних Spotify Tracks Dataset у форматі CSV.

Аналіз виконувався мовою Python із використанням бібліотек pandas, matplotlib, seaborn та scikit-learn.

На початковому етапі було виконано попередню обробку даних. Було перевірено наявність пропущених значень, виконано очищення набору даних та підготовлено числові ознаки для подальшого аналізу.

3.1. Описовий аналіз даних

Було досліджено розподіли основних аудіофіч, зокрема energy, danceability, loudness, acousticness та popularity. Аналіз показав, що більшість композицій мають середній або високий рівень енергійності та танцювальності.




Рис. 1: Розподіли основних аудіофіч

3.2. Кореляційний аналіз

Наступним етапом було виконано кореляційний аналіз між аудіофічами. Найбільш помітні залежності спостерігалися між energy та loudness, а також між acousticness та energy.




Рис. 2: Матриця кореляцій аудіофіч

Кореляційна матриця дозволила виявити як позитивні, так і негативні взаємозв'язки між характеристиками композицій.

3.3. Кластеризація треків

Для групування композицій було використано алгоритм KMeans. Перед побудовою моделі було виконано нормалізацію ознак. Кількість кластерів обиралася на основі методу ліктя та silhouette score.




Рис. 3: Вибір кількості кластерів методом ліктя

Після визначення оптимальної кількості кластерів було побудовано фінальну модель кластеризації.




Рис. 4: Візуалізація кластерів після PCA

Результати показали, що композиції формують декілька відносно стабільних груп із подібними характеристиками.

3.4. Класифікація популярності треків

Для прогнозування популярності треків використовувалися моделі Logistic Regression та Random Forest. Цільова змінна формувалася шляхом поділу треків на популярні та непопулярні відносно медіанного значення popularity.

Random Forest продемонстрував кращу якість класифікації порівняно з Logistic Regression, що свідчить про наявність нелінійних залежностей у даних.




Рис. 5: Важливість ознак у моделі Random Forest

Найбільш значущими ознаками для прогнозування популярності виявилися energy, danceability, loudness та valence.

accuracy		f1		
model				
RandomForest	0.7787	0.7889		
LogisticRegression	0.5742	0.5943		
	precision	recall	f1-score	support
0	0.81	0.73	0.77	11317
1	0.76	0.82	0.79	11393
accuracy			0.78	22710
macro avg	0.78	0.78	0.78	22710
weighted avg	0.78	0.78	0.78	22710
[[8294 3023]				
[2003 9390]]				

Рис. 6: Матриця помилок моделей Random Forest та Logistic Regression

Отримані результати підтверджують ефективність використання методів інтелектуального аналізу даних для дослідження музичних композицій та прогнозування їх популярності.

4. Висновки та подальші кроки

У межах роботи було проведено комплексний аналіз набору даних Spotify Tracks Dataset із використанням методів інтелектуального аналізу даних та машинного навчання.

У процесі дослідження було виконано очищення та підготовку даних, проведено описовий та кореляційний аналіз аудіофіч, а також реалізовано кластеризацію музичних композицій. Результати показали наявність закономірностей між окремими характеристиками треків та їх популярністю.

Модель Random Forest продемонструвала кращі результати класифікації порівняно з Logistic Regression, що свідчить про складну структуру взаємозв'язків між ознаками музичних композицій. Аналіз важливості ознак показав, що найбільший вплив на популярність треків мають energy, danceability, loudness та valence.

Кластеризація дозволила виділити групи композицій зі схожими характеристиками, а PCA-візуалізація підтвердила наявність структурованих патернів у наборі даних.

Практична цінність роботи полягає у демонстрації можливостей застосування методів інтелектуального аналізу даних для аналізу музичних сервісів та побудови моделей прогнозування.

Подальшим розвитком роботи може бути:

1. Використання більш складних ансамблевих моделей.
2. Дослідження часових характеристик музичних трендів.
3. Побудова рекомендаційної системи.

4. Аналіз текстів пісень та їх впливу на популярність.
5. Використання нейронних мереж для класифікації композицій.

Отримані результати підтверджують ефективність використання сучасних методів аналізу даних для дослідження музичних платформ та прогнозування популярності контенту.

Література

- [1] Spotify Tracks Dataset. Kaggle dataset.
- [2] Scikit-learn: Machine Learning in Python. User Guide.
- [3] The pandas development team. Pandas documentation.